

UNIVERSIDAD AUTÓNOMA DE GUADALAJARA

**Prototipo de Plataforma Estructurada
para el Acceso a Sistemas de
Transparencia Gubernamental**

presentado por
Esperanza Citlali García Medina

Para obtener el título de
Maestría en Ciencias Computacionales

en la
Facultad de Electrónica y Ciencias Computacionales

8 de abril de 2015

“La educación es el arma más poderosa que puedes usar para cambiar el mundo.”

Nelson Mandela

RESUMEN

En este trabajo se realizó una síntesis de los principales conceptos relacionados con Conocimiento Abierto, tales como Datos Abiertos y Contenido Abierto, a su vez se repasó la historia de como ha evolucionado el movimiento Datos Abiertos a través de los años. Los Gobiernos ahora están liberando información que solía ser privada con el objetivo de ser mas transparentes y eficientes, y para hacerlo, muchos de ellos están aprovechando las tecnologías ya existentes tales como la plataforma CKAN, mantenida por la Fundación Conocimiento Abierto. Sin embargo, el proceso de consulta y análisis de la información es aún muy compleja. Dentro de este documento se discuten algunos de los problemas relacionados con datos abiertos y se sugiere un enfoque diferente a la búsqueda de información no estructurada a través de la implementación de una aplicación de búsqueda basada en Apache Lucene.

Palabras Clave:

Conocimiento Abierto, Datos Abiertos, Datos de Gobierno, Indexado, Motor de Búsqueda.

ABSTRACT

In this work, a summary has been done of the main concepts related to Open Knowledge such as Open Data and Open Content, also an overview of the history about how the Open Data movement has evolved through the years has been covered. Governments are now releasing data so as to be more transparent and efficient, and in order to do so, many of them are taking advantage of the technologies that already exist such as the CKAN platform maintained by the Open Knowledge Foundation. However the query and analysis processes are still very complex. Within this document some of the issues related to open data are discussed and a different approach to the search of unstructured data is suggested through the implementation of a search application based on Apache Lucene.

Keywords:

Open Knowledge, Open Data, Government Data, Indexing, Search Engine.

Agradecimientos

A mi asesor de tesis, el Dr. Rogelio Dávila por sus consejos en el desarrollo de este proyecto.

A mis maestros por todas sus enseñanzas.

A mi marido, Romeo por todo su apoyo y paciencia en mis noches de desvelo y estrés.

A mi familia, por estar ahí siempre.

Índice general

Resumen	II
Agradecimientos	III
Índice de Figuras	VI
Índice de Cuadros	VII
Abreviaciones	VIII
1. Introducción	1
1.1. Datos Abiertos de Gobierno	3
2. Descripción del Problema	5
3. Definición del Problema	8
4. Pregunta de Investigación	9
5. Objetivos de la Investigación	10
5.1. Objetivo General	10
5.2. Objetivos Particulares	10
6. Resultados Esperados	11
7. Delimitación de la Investigación	12
8. Justificación	13
9. Bases Teóricas	15
9.1. Marco Historico y Contextual	15
9.2. Marco Referencial	17
9.3. Términos Básicos	18
10.Propuesta de Solución	19
10.1. Selección de un Conjunto de Datos	19
10.2. Recuperación de datos usando la API de CKAN	21
11.Implementación de la Solución	22
11.1. Configuración de Ambiente	22
11.2. Arquitectura	22

11.3. Detalles Técnicos	22
12.Resultados Obtenidos	23
A. Anexo - Resumen de formatos de archivos más comunes	24
B. Anexo - Ejemplos de implementaciones CKAN en el mundo	25
C. Calendario de Actividades	35
Bibliografía	36

Índice de figuras

8.1. Los datos abiertos pueden ayudar a generar mas de 3 billones de dólares al año en el mundo.	13
9.1. Catálogo de Datos Abiertos del Gobierno de México.	16
B.1. Datos Abiertos del Gobierno de Amsterdam.	25
B.2. Datos Abiertos del Gobierno de África.	26
B.3. Datos Abiertos del Gobierno de Australia.	27
B.4. Datos Abiertos del Gobierno de Berlin.	28
B.5. Datos Abiertos del Gobierno de Brasil.	29
B.6. Datos Abiertos del Gobierno de Buenos Aires.	30
B.7. Datos Abiertos del Gobierno de Montreal.	31
B.8. Datos Abiertos del Gobierno de Montreal.	32
B.9. Datos Abiertos del Gobierno del Reino Unido.	33
B.10. Datos Abiertos del Gobierno de Estados Unidos de América.	34

Índice de cuadros

10.1. Variables para fórmula de cálculo de el tamaño de muestra	19
10.2. Valores reales para fórmula de cálculo de el tamaño de muestra	20
10.3. Selección de tamaño de muestra por tipo de formato	20

Abreviaciones

API	A pplication P rogram I nterface
ODM	O pen D ata M ovement
OKF	O pen K nowledge F oundation
CKAN	C omprehensive K nowledge A rchive N etwork

Introducción

En la última década, un movimiento ha surgido gradualmente en todo el mundo, conocido como el movimiento de los Datos Abiertos (Open Data Movement en Inglés). Su objetivo es la difusión del Conocimiento Abierto en su mas amplio sentido.

La Fundación Conocimiento Abierto (Open Knowledge Foundation en Inglés) define el conocimiento abierto como:

«cualquier contenido, información o dato que puede ser libremente utilizado, reutilizado y redistribuido -sin restricciones legales, tecnológicas o sociales- . [...] El conocimiento abierto es en lo que se convierten los datos abiertos cuando son útiles, usables y utilizados» [1]

Los Datos Abiertos son por ende, la base de construcción en la que se fundamenta el Conocimiento Abierto.

El término de Datos Abiertos es una práctica que tiene como objetivo que determinados tipos de datos estén disponibles para todo el mundo sin restricciones de derechos de autor, patentes u otro mecanismo de control. Dicho concepto no es nuevo, sin embargo, ha ganado mayor relevancia con el aumento en la popularidad de tecnologías como el Internet y la Red Informática Mundial (World Wide Web en Inglés o WWW), así como a la acumulación masiva de datos (Big Data en Inglés).

La filosofía detrás de éste movimiento se centra en 3 principales aspectos:

- 1) Disponibilidad y Acceso: Los datos deben de estar disponibles preferentemente mediante una descarga de Internet. Los datos deben de ser presentados en un formato conveniente y que permita modificaciones fácilmente.
- 2) Reutilización y Redistribución: Los datos deben de estar disponibles bajo términos que permitan su reutilización y redistribución, incluida la composición con otros conjuntos de datos. Los datos deben de ser capaces de ser leídos por una computadora.
- 3) Participación Universal: Cualquier persona debe de tener la posibilidad de usar, reutilizar y redistribuir datos abiertos sin discriminación alguna.

Los tipos de Datos Abiertos comprenden campos de estudio muy diversos como lo son Cultural, Científico, Finanzas, Estadística, Climatológica, Ambiental, de Transporte y Gubernamental.

1.1. Datos Abiertos de Gobierno

Los Datos Abiertos de Gobierno son un proyecto de la Fundación Conocimiento Abierto enfocada exclusivamente a la publicación de datos producidos por instituciones gubernamentales. Varios países incluidos los Estados Unidos Americanos, Reino Unido, Canada, Nueva Zelanda y recientemente México han anunciado sus propias iniciativas hacia la apertura de su información. [2–7]

Ya es posible señalar una gran cantidad de áreas donde los Datos Abiertos de Gobierno están creando valor. Algunos ejemplos de ellos son: [8, 9]

- En términos de transparencia, proyectos como el Finlandés 'árbol de impuestos' o el Británico '¿A donde va mi dinero?' nos muestran como se gasta el dinero de los impuestos por el gobierno. También páginas web como la página Danes folketsting.dk permite monitorear las actividades en el parlamento y el proceso de construcción de leyes para poder saber exactamente qué está sucediendo y que representantes están involucrados.
- Los Datos Abiertos de Gobierno también pueden ayudar a tomar mejores decisiones en la vida personal, o habilitar a las personas para tener una participación más activa en la sociedad. Una mujer en Dinamarca construyó el sitio web findtoilet.dk para mostrar todos los baños públicos y ayudar a las personas con problemas de incontinencia a salir nuevamente. En Holanda existe un servicio vervuilingsalarm.nl que te advierte con un mensaje de la calidad de el aire en tu comunidad. En Nueva York se puede encontrar fácilmente donde sacar el perro a pasear así como conocer otras personas que frecuentan el mismo parque. Servicios como 'mapumental' en Reino Unido y 'Magnificent' en Alemania te permiten encontrar un lugar para vivir teniendo en consideración la duración de el traslado al trabajo, los precios de las casas y la calidad de el area. Todos estos ejemplos utilizan datos abiertos.
- Económicamente, los datos abiertos también son de gran importancia. Varios estudios han estimado el valor de los datos abiertos es superior a los diez mil millones de Euros anualmente. Nuevos productos y compañías están utilizando esta información por ejemplo, la página web Danesa husetsweb.dk te ayuda a encontrar manera

de mejorar la eficiencia energética en el hogar basado en información de los subsidios gubernamentales. Google Translate utiliza la enorme cantidad de documentos abiertos para entrenar sus algoritmos de traducción y por lo tanto mejorando la calidad de su servicio.

- Los datos abiertos son de gran valor para el gobierno mismo ya que colabora a incrementar su eficiencia y efectividad. Por ejemplo el Ministerio de Educación Alemán ha publicado toda la información relacionada con educación en línea para su reutilización. Desde entonces, el número de preguntas que ellos reciben a disminuido reduciendo la carga de trabajo y costos.

Aún cuando ya hay numerosos ejemplos de las maneras en que los datos abiertos están creando valor tanto social como económico, todavía hay un área muy grande de oportunidad para descubrir nuevos campos de investigación.

Los sitios web que forman parte de el proyecto Datos Abiertos de Gobierno están desarrollados utilizando una plataforma tecnológica conocida como CKAN (Comprehensive Knowledge Archive Network en Inglés), también mantenida por la Fundación Conocimiento Abierto. CKAN es un sistema para el almacenamiento y distribución de información que provee herramientas para publicar, compartir, buscar y utilizar los datos. CKAN esta enfocado a gobiernos regionales y nacionales, compañías y organizaciones que quieren hacer que sus datos sean abiertos y disponibles al público. [10]

Éste documento investiga la estructura e implementación de la plataforma CKAN en diferentes instituciones gubernamentales, particularmente en la plataforma del Gobierno Mexicano, sin embargo será aplicable para cualquier otra institución que este desarrollada utilizando las mismas tecnologías, con la finalidad de proponer una nueva herramienta capaz de extraer la información proporcionada por las instituciones gubernamentales y estructurarla de una manera uniforme utilizando en un formato genérico y permitir así la consulta y análisis de la información de una manera más simple y natural.

Descripción del Problema

Los catálogos de Datos Abiertos permiten que se creen herramientas de todo tipo para medir y estudiar lo que ocurre a partir de la información recolectada. Nuevas tecnologías permiten ahora construir servicios para responder automáticamente preguntas como: ¿Cuál es el eje carretero más largo en un país? ¿Qué porcentaje del presupuesto se destina para el alumbrado público? ¿En qué región existen mejores oportunidades de trabajo? Mucha de la información necesaria para responder estas preguntas es generada por instituciones públicas, sin embargo, frecuentemente la información no está disponible en un formato que sea fácil de utilizar.

En México, en el año 2014, como parte de la Política de Datos Abiertos, el Gobierno Mexicano ha puesto a disposición de toda la población la mayor cantidad de información posible de todo lo que ocurre en las entidades de Gobierno y con cada programa social que se desarrolla en el país a través de la plataforma llamada `datos.gob.mx`. De acuerdo con el comunicado oficial del Gobierno Federal, desde dicha página se puede «acceder, descargar, y utilizar libremente los datos abiertos que el Gobierno de la República genera y recolecta, con el fin de innovar, emprender, incrementar la transparencia, eficientar al gobierno y promover la innovación cívica.» [11]

Una investigación realizada en la Universidad de Waterloo en Canadá en el año de 2014 analiza diferentes casos de uso de sistemas que fueron implementados utilizando datos abiertos y refleja la complejidad que implica el trabajar con ellos: [12]

- Hay situaciones en las que para poder hacer un análisis se requiere información tanto de instituciones gubernamentales como no gubernamentales. ¿Cómo aseguramos que toda la información necesaria para un proyecto se encuentra disponible?
- Aplicaciones que requieren información de último momento, como una aplicación para predecir el clima, requiere de la información más actualizada posible.

¿Cómo podemos asegurar que la información requerida aún es válida y que sea actualizada en un periodo aceptable de tiempo?

- Algunas veces es necesario consultar información no propia del documento pero de su publicación, por ejemplo, lugar y fecha de publicación ¿Cómo puedo acceder a herramientas que permitan consultar metadata y palabras clave de un documento?
- Liberar datos abiertos puede tener efectos en la privacidad de los individuos afectados cuando alguna información personal pudiera ser inferidos por datos abiertos. ¿Cómo puedo asegurar que los datos abiertos que han sido compartidos no implican potenciales problemas de seguridad o privacidad?

Idealmente para un usuario debería ser posible fácilmente realizar tareas tales como: [8]

- Descubir la existencia de determinado conjunto de datos.
- Acceder a los datos para su investigación y análisis.
- Encontrar la información detallada describiendo la información y su proceso de producción.
- Acceder a las fuentes de datos e instrumentos de colección con los cuales la información fue colectada.
- Efectivamente comunicarse con las agencias involucradas en el proceso de producción, almacenamiento y distribución de la información.
- Compartir el conocimiento con otros usuarios.

Sin embargo, la realidad aún se aleja de los ideales de el Movimiento Conocimiento Abierto. No es suficiente con declarar los conjuntos de datos como 'abiertos' para que estos datos tenga un uso práctico para el ciudadano común.

Cuando estos datos son liberados en su formato crudo (raw en Inglés), sólo tienen sentido para los especialistas técnicos que saben como extraerlos, interpretarlos y utilizarlos. De nuevo, esta información sigue estando únicamente a disposición de ciertos grupos privilegiados.

Si se pretende que esta información tenga un alcance masivo y sea significativa para la ciudadanía en general, debemos de enfocarnos en solucionar los principales retos a los que se enfrenta un usuario es su búsqueda de datos abiertos los cuales son:

- La navegación en la plataforma no es intuitiva para un usuario que no este familiarizado con entornos tecnológicos.
- Los formatos en que los datos son presentados son muy diversos, varía desde archivos en formatos zip, csv, xml, json, kmz, etc.
- El motor de búsqueda integrado a la plataforma es poco eficiente por lo que un usuario debe saber de antemano cual es la fuente que esta generado los datos de su interés, de otra manera tiene que recurrir a la búsqueda mediante etiquetas que no siempre pueden estar disponibles.

Definición del Problema

El presente trabajo acota la investigación a un ejemplo de implementación de plataforma CKAN en particular, siendo el sitio web de Datos Abiertos del Gobierno Mexicano (datos.gob.mx) el seleccionado por ser un ejemplo práctico y de mayor beneficio para la comunidad local.

Cabe destacar que aún cuando la aplicación esta enfocada a esta plataforma, aplica prácticamente a cualquier otra que cuente con la misma estructura, por lo que este prototipo puede ser reutilizable y ajustarse a otras necesidades de implementación.

Con ésta aplicación se pretende contribuir a el desarrollo de herramientas que pongan a el alcance de todo el mundo la información pública que las instituciones gubernamentales nos proporcionan con la finalidad de despertar en ellos la creatividad y que en un futuro cercano surjan ideas inovadoras e interesantes maneras de interpretar los datos abiertos.

Pregunta de Investigación

¿Cómo desarrollar una aplicación que permita generar valor a partir de la consulta, uso y análisis de los datos abiertos liberados por las organizaciones gubernamentales a una audiencia más amplia y de manera fácilmente accessible?

Objetivos de la Investigación

5.1. Objetivo General

Desarrollar una aplicación que permita extraer los datos abiertos disponibles en una plataforma de datos abiertos de instituciones gubernamentales y que una vez obtenidos, los diferentes tipos de archivos que existen en diversos formatos sean estructurados uniformemente utilizando un formato único, de tal manera que puedan ser consultados y analizados de una manera más simple y natural.

5.2. Objetivos Particulares

1. Desarrollar un programa que inspeccione las páginas de una manera metódica y automatizada (Web Crawler en Inglés) para navegar a través del sitio de Datos Abiertos del Gobierno Mexicano (datos.gob.mx) y descargar la información requerida utilizando el API de CKAN mediante la ejecución de un script en lenguaje Python.
2. Desarrollar un algoritmo para el procesamiento e indexado de la información que produzca como resultado archivos en formato JSON.
3. Proveer las capacidades de búsqueda de texto y definir un lenguaje de consulta utilizando las capacidades que la herramienta Apache Lucene proporciona.

Resultados Esperados

Como producto de el desarrollo de esta tesis y su proyecto de intervención se espera obtener una aplicación que aporte novedades en el ámbito de sistemas de búsqueda orientado a archivos utilizando un método de búsqueda avanzada basado en Apache Lucene y empleando como fuente de información los datos abiertos liberados por Instituciones Gubernamentales.

Dado que la aplicación estará desarrollada en su totalidad con herramientas de código abierto y diseñada para alimentarse con información de datos abiertos, es natural que la aplicación misma también sea distribuida libremente por lo que se espera que la implementación y el código fuente este disponible en un repositorio público al acceso de cualquier persona.

Así mismo, se espera que la aplicación pueda ser publicada en un servidor público y gratuito para que este disponible a la ciudadanía en general.

Los requerimientos básicos para la implementación de la aplicación comprenden:

- La navegación en la plataforma deberá ser sencilla e intuitiva para cualquier usuario.
- Los formatos en que los datos son procesados deberá ser uniforme.
- El motor de búsqueda deberá permitir consultas tanto por metadatos, etiquetas y al propio contenido de un documento.

Alcanzar estos objetivos contribuirá a un cambio cultural al construir la capacidad de comprensión de la información, así como la habilidad de encontrar, utilizar y compartir datos y alentar la colaboración entre gobiernos, negocios y sociedad civil para combatir los principales retos de la actualidad.

Delimitación de la Investigación

A la fecha, la única manera de descargar datos de una plataforma CKAN, es a través de su propia API. No hay un servicio web que permita descargar los datos como conjunto, si no que tienes que recorrer la lista de resultados uno a uno. Hay 3 maneras en las que se puede filtrar los resultados: por paquete, por grupo y por etiquetas.

Debido a esta restricción, para los propósitos de construir un prototipo, se comenzará a trabajar con un subconjunto de datos inicial en los formatos XML, XLS, CSV y JSON que será una copia no actualizada de los datos en el sistema, por lo que eventualmente no serán sincronizados a la última versión disponible.

La investigación no comprende el proceso de implementar un sitio web basado en la plataforma CKAN, sólo comprende la tarea de cómo consumir la información de una plataforma ya existente y procesarla para mejorar el proceso de búsqueda.

Los archivos que contienen imágenes (formatos PNG, JPG and GIF) no serán incluidos como parte de éste estudio.

El proyecto de intervención es un prototipo que será mejorado de manera incremental en futuras versiones.

Justificación

La compañía McKinsey's publicó un estudio en Octubre de 2013 [13] en el que valora el potencial en términos económicos de siete sectores de actividad: educación, transporte, productos de consumo, energía eléctrica, petróleo, gas, salud y economía familiar.




FIGURA 8.1: Los datos abiertos pueden ayudar a generar mas de 3 billones de dólares al año en el mundo.

La investigación sugiere que esos siete sectores exclusivamente pudieran generar mas de 3 billones de dólares al año de los cuales 1,1 billón corresponde a Estados Unidos, 900.000 millones a Europa y los otros 1,7 billones al resto del mundo como resultado de la utilización de datos abiertos.

Otro punto interesante en el estudio, revela cómo se ha incrementado el número de iniciativas de portales de datos abiertos así como el número de conjuntos de datos disponibles en cada portal. Por ejemplo, en 2009, el Gobierno de Estados Unidos publicó los primeros 47 conjuntos de datos y avanzó rápidamente hasta llegar a más de 90000 en Octubre de 2013. El Gobierno del Reino Unido alcanza los 10000 conjuntos de datos para esa misma fecha.

Por su parte, México se integró a esta iniciativa en Abril de 2014 y a la fecha en Abril de 2015 cuenta con un total de 357 conjuntos de datos.

Estadísticas como la anterior está dando pie para la creación de nuevos negocios y ayudando a compañías ya establecidas a explorar nuevos segmentos de mercado, definir nuevos productos y servicios y mejorar la eficiencia y efectividad de sus operaciones.

Aún cuando el fenómeno de datos abiertos aún esta en sus inicios en nuestro país, podemos observar un claro potencial para utilizar la información como un instrumento para ayudar a las instituciones gubernamentales a reemplazar la toma de decisiones tradicional por un enfoque orientado a datos. El análisis de datos abiertos también puede ayudar a descubrir preferencias de los ciudadanos, permitiendo a las instituciones mejorar sus servicios y descubrir anomalías y problemas.

Con base en esta información es que desarrollar una aplicación enfocada a facilitar el proceso de búsqueda y análisis de los datos abiertos disponibles prueba ser de gran conveniencia y viabilidad en nuestro entorno global actual.

Bases Teóricas

9.1. Marco Historico y Contextual

El término datos abiertos apareció por primera vez en 1995, en un documento de la Agencia Científica Americana. Ahí se discutía acerca de la difusión de información geofísica y ambiental y promovía una apertura de el intercambio de información científica entre diferentes países como requisito para el análisis y la comprensión de éstos fenómenos globales.

Pero fue hasta que los ideales científicos se cruzaron con los ideales del software libre, que surgió el concepto tal y como lo conocemos hoy en día.

En Diciembre de 2007, en Sebastopol, California, un grupo de 30 líderes entre ellos Tim O'Reilly and Lawrence Lessig [14] se reunieron para discutir y definir el concepto de datos públicos y abiertos así como los principios que permiten evaluarlos. Los resultados hasta la fecha han excedido las expectativas. En Enero de 2009, el Presidente Barack Obama tomo el mando de los Estados Unidos de América y firmó el Memorando para la Transparencia y el Gobierno Abierto, declarando « La información mantenida por el Gobierno Federal es un recurso nacional. Mi administración tomará las acciones apropiadas, consistentes con la ley, para difundir la información rápidamente en formatos que el público pueda rápidamente consultar y utilizar » [15]

En Mayo de ese mismo año, Data.gov iniciaba operaciones con únicamente 47 conjuntos de datos. Ahora, 6 años después la plataforma contiene más de 100,000 conjuntos de datos de 227 agencias y organizaciones locales, estatales y federales.

Por su parte en México, El 20 de septiembre de 2011, el Presidente de la República Mexicana presentó ante la Alianza para el Gobierno Abierto, el plan de acción de México. Los gobiernos que se incorporen a la Alianza para el Gobierno Abierto elaborarán un Plan de Acción que contenga compromisos concretos. En base a esos compromisos se lanzó el Datatron, una encuesta digital para conocer más sobre la demanda de Datos Abiertos y abrir el proceso a una mayor participación. El Datatron pedía a los encuestados elegir qué datos de gobierno le gustaría conocer. Como resultado de dicha encuesta es que surge la plataforma de Datos Abiertos del Gobierno Mexicano (datos.gob.mx) Es así que el estudio se desarrolla dentro de un contexto en donde el Movimiento Datos Abiertos ha alcanzado amplios niveles de popularidad dentro de los gobiernos regionales y nacionales. El proyecto de intervención comprende el total de 358 conjuntos de datos abiertos publicados desde Abril del 2014 a Abril del 2015 en la plataforma de Datos Abiertos del Gobierno Mexicano (datos.gob.mx)



FIGURA 9.1: Catálogo de Datos Abiertos del Gobierno de México.

9.2. Marco Referencial

La propuesta de estudio esta fundamentada tecnológicamente en una librería de código abierto para búsqueda y recuperación de la información conocido como Lucene.

Lucene fue originalmente escrita en en lenguaje de programación Java por Doug Cutting (creador también de Hadoop) en 1997. [16] En el año 2000, Lucene se convirtió en una librería de código abierto alojada en SourceForge y rápidamente ganó adeptos por lo que en 2001 fue adoptada por la fundación Apache. El número de contribuyentes creció sostenidamente, y a través de los años, Lucene ha sido traducido a múltiples lenguajes de programación, incluidos C++, C#, Perl, y Python. En la versión original de Java o en cualquiera de sus otras versiones, Lucene es ampliamente usado en el mundo. Ejemplos de sus aplicaciones incluyen [17]:

1. Bixee - Motor de Búsqueda de empleos en India.
2. Casabuscador - Motor de Búsqueda para la renta y venta de bienes raíces en España.
3. CiteSeerX - Motor de Búsqueda de documentos académicos.
4. CodeCrawler - Motor de Búsqueda de código fuente.
5. Dialo.de - Motor de Búsqueda para el directorio de servicios sección amarilla para Alemania.
6. Doctoralia - Motor de Búsqueda para profesionales de la salud.
7. Eclipse - Motor de Búsqueda para la documentación dentro de el entorno gráfico (IDE) de Eclipse.
8. Keljob.com - Motor de Búsqueda de curriculum vitae.
9. Twitter Trends - Motor de Búsqueda para la herramienta que analiza las tendencias en Twitter.

9.3. Términos Básicos

Apache Lucene:

Lucene es un software de recuperación de información (IR) de código abierto. Es una API flexible que permite añadir capacidades de indexación y búsqueda a cualquier sistema que se esté desarrollando.

Araña Web:

También conocida como Web Crawler por su término en Inglés es un programa que inspecciona las páginas web de forma metódica y automatizada. Uno de los usos más frecuentes que se les da consiste en crear una copia de todas las páginas web visitadas para su procesamiento posterior por un motor de búsqueda que indexa las páginas proporcionando un sistema de búsquedas rápido.

Indexado:

Acción de agregar una o más páginas web ó documentos a las bases de datos de un buscador, para que estas aparezcan en los resultados de búsquedas de los mismos.

Propuesta de Solución

10.1. Selección de un Conjunto de Datos

Hasta Abril de 2015 se reportan un total de 358 conjuntos de datos disponibles en el sitio web <http://catalogo.datos.gob.mx/dataset>

El tamaño de la muestra seleccionada para este estudio fue calculado con base en los procedimientos sugeridos en la teoría del muestreo y probabilidad. Las variables a considerar son las siguientes:

Variable	Descripción
n	Tamaño de la muestra
N	Tamaño del universo
p	Probabilidad de ocurrencia
q	Probabilidad de no ocurrencia
Me	Margen de error o precisión
Nc	Nivel de confianza o exactitud

CUADRO 10.1: Variables para fórmula de cálculo de el tamaño de muestra

$$n = \frac{Npq}{\left[\frac{Me^2}{Nc^2} (N - 1) \right] + PQ}$$

Variable	Descripción
N	358
p	.5 (Mayor punto de incertidumbre 50 %)
q	$1 - .5 = .5$
Me	5 (Margen de error o precisión +/- 5 %)
Nc	1.96 (95 % de nivel de confianza o exactitud)

CUADRO 10.2: Valores reales para fórmula de cálculo de el tamaño de muestra

Al substituir la fórmula obtenemos un tamaño de muestra recomendado de: **186**

La distribución de los documentos de la muestra, organizados por tipo de formato e institución que lo genera, fue seleccionado de acuerdo a la disponibilidad de los mismos y se distribuye de la siguiente manera:

Cantidad	Formato	Instituciones
CSV	89	PEMEX, SAGARPA
XML	55	PEMEX
JSON	3	PROMEXICO
XLS	2	SHCP
TXT	37	SEDESOL

CUADRO 10.3: Selección de tamaño de muestra por tipo de formato

10.2. Recuperación de datos usando la API de CKAN

Implementación de la Solución

11.1. Configuración de Ambiente

11.2. Arquitectura

11.3. Detalles Técnicos

Resultados Obtenidos

Anexo - Resumen de formatos de archivos más comunes

JSON

Acrónimo de JavaScript Object Notation, es un formato ligero para el intercambio de datos. JSON es un subconjunto de la notación literal de objetos de JavaScript que no requiere el uso de XML.

XML

Siglas en inglés de eXtensible Markup Language ('lenguaje de marcas extensible'), es un lenguaje de marcas desarrollado por el World Wide Web Consortium (W3C) utilizado para almacenar datos en forma legible.

XLS

La extensión de archivo por defecto para aplicaciones de hojas de cálculo.

CSV

Tipo de documento en formato abierto sencillo para representar datos en forma de tabla, en las que las columnas se separan por comas y las filas por saltos de línea.

TXT

La extensión para archivo compuesto únicamente por texto sin formato, sólo caracteres, lo que lo hace también legible por humanos.

ZIP

Formato de compresión sin pérdida, muy utilizado para la compresión de datos como documentos, imágenes o programas.

KMZ

Es un lenguaje de marcado basado en XML para representar datos geográficos en tres dimensiones en formato comprimido.

Anexo - Ejemplos de implementaciones CKAN en el mundo

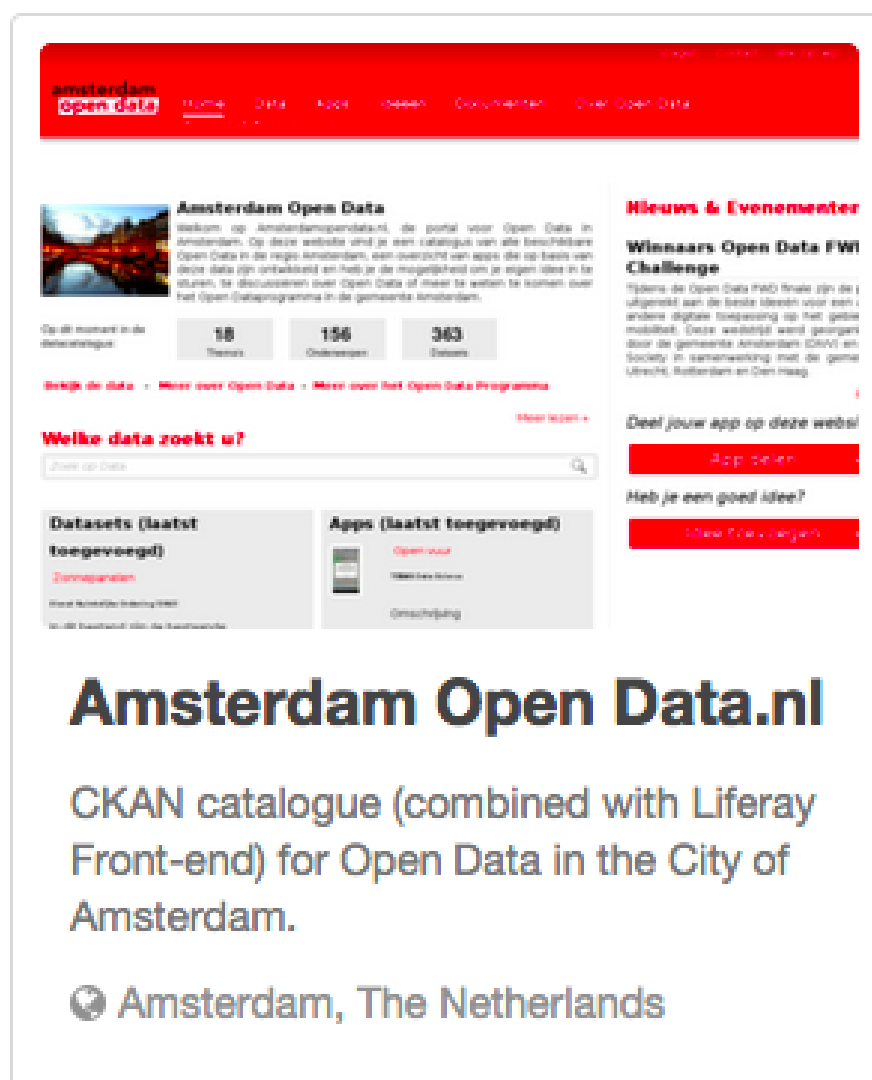


FIGURA B.1: Datos Abiertos del Gobierno de Amsterdam.




FIGURA B.2: Datos Abiertos del Gobierno de África.




FIGURA B.3: Datos Abiertos del Gobierno de Australia.




FIGURA B.4: Datos Abiertos del Gobierno de Berlin.



dados.gov.br

The Brazilian national portal at <http://dados.gov.br/> was built using a highly participative process, with planning and development meetings open to all interested citizens. It used CKAN in line with government policy to use free and open-source software where possible.


 Brazil

FIGURA B.5: Datos Abiertos del Gobierno de Brasil.




FIGURA B.6: Datos Abiertos del Gobierno de Buenos Aires.




FIGURA B.7: Datos Abiertos del Gobierno de Montreal.




FIGURA B.8: Datos Abiertos del Gobierno de Montreal.

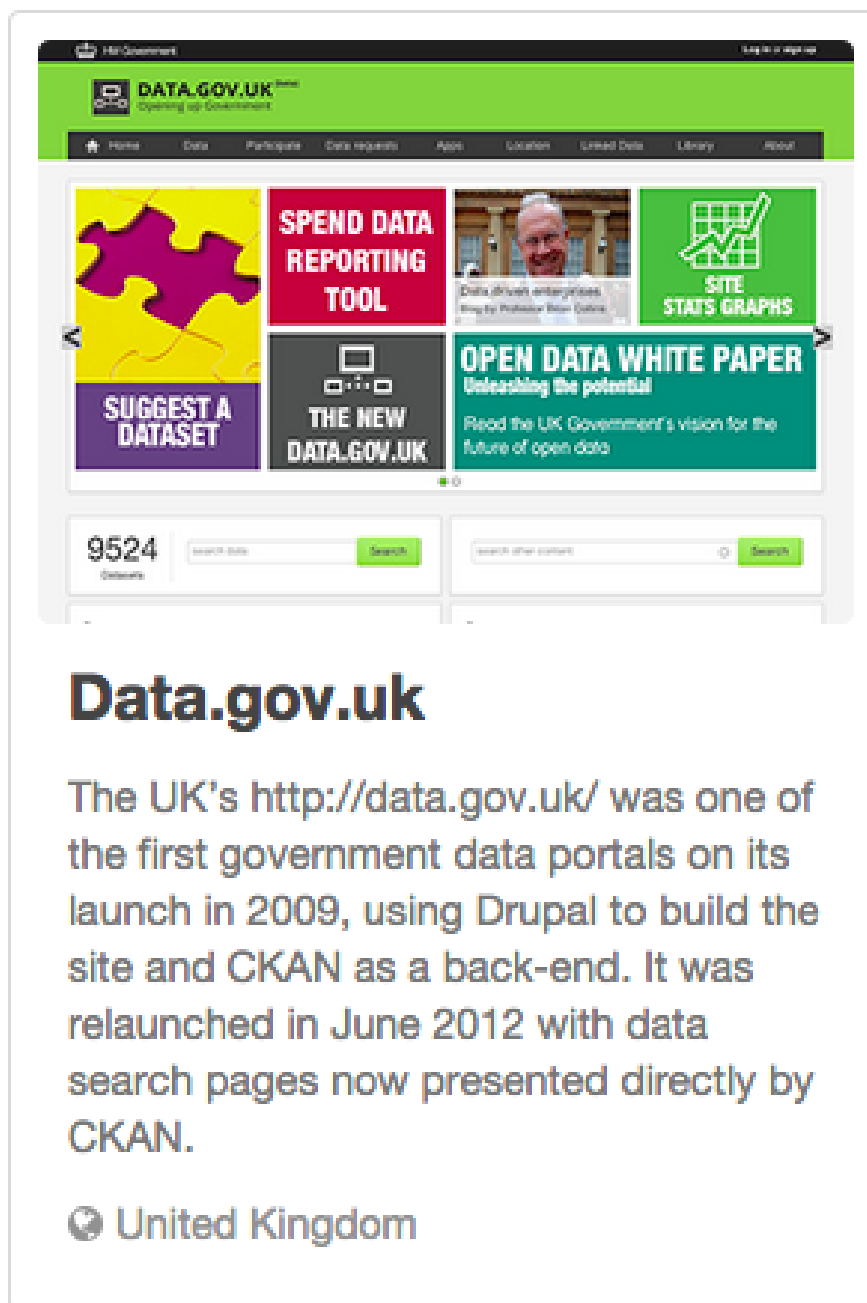


FIGURA B.9: Datos Abiertos del Gobierno del Reino Unido.



FIGURA B.10: Datos Abiertos del Gobierno de Estados Unidos de América.

Calendario de Actividades

Bibliografía

- [1] Open Knowledge. What is open?, Febrero 2015. URL <https://okfn.org/opendata/>.
- [2] Open Government Data. Open government data, Diciembre 2014. URL <http://opengovernmentdata.org/>.
- [3] Data.Gov. U.s. government open data, Enero 2015. URL <http://www.data.gov/>.
- [4] Data.Gov. U.k. government open data, Enero 2015. URL <http://data.gov.uk/>.
- [5] Data.Gov. Canada government open data, Enero 2015. URL <http://open.canada.ca/en>.
- [6] Data.Gov. New zealand government open data, Enero 2015. URL <https://data.govt.nz/>.
- [7] Data.Gov. Mexico government open data, Enero 2015. URL <http://datos.gob.mx/>.
- [8] Open Knowledge. Open data handbook, Diciembre 2014. URL <http://opendatahandbook.org/pdf/OpenDataHandbook.pdf>.
- [9] UK Government. Open data white paper unleashing the potential, Febrero 2015. URL <https://www.gov.uk/government/uploads/system/uploads/attachmentdata/file/78946/CM8353acc.pdf>.
- [10] CKAN. The open source data software portal, Diciembre 2014. URL <http://ckan.org/>.
- [11] Presidencia de la República. ¿ya conoces datos.gob.mx?, Junio 2014. URL <http://www.gob.mx/presidencia/datos-abiertos/ya-conoces-datos-gob-mx/>.

- [12] Cowan D. ; Alencar P. ; McGarry F. Perspectives on open data: Issues and opportunities. *Software Science Technology and Engineering (SWSTE) 2014 IEEE International Conference on*, pages 24–33, June 2014. URL <http://link.aip.org/link/?RSI/62/1/1>.
- [13] James Manyika; Michael Chui; Peter Groves; Diana Farrell; Steve Van Kuiken; Elizabeth Almasi Doshi. Open data: Unlocking innovation and performance with liquid information (2013), Enero 2015. URL http://www.mckinsey.com/insights/business_technology/open_data_unlocking_innovation_and_performance_with_liquid_information.
- [14] D. Lathrop and L. Ruma. *Open Government: Collaboration, Transparency, and Participation in Practice*. O'Reilly Series. O'Reilly Media, Incorporated, 2010. ISBN 9780596804350. URL <http://books.google.com.mx/books?id=9UibAgAAQBAJ>.
- [15] Barak Obama. Memorandum on transparency and open government, Enero 2009. URL <https://www.whitehouse.gov/the-press-office/transparency-and-open-government>.
- [16] Michael McCandless; Erik Hatcher; Otis Gospodnetic. *Lucene in Action, Second Edition*. Manning Publications, Stamford, CT, 2010.
- [17] Apache Lucene. Lucene powered by, Septiembre 2014. URL <http://wiki.apache.org/lucene-java/PoweredBy>.