#### UNIVERSIDAD AUTÓNOMA DE GUADALAJARA

# Prototipo de Plataforma Estructurada para el Acceso a Sistemas de Transparencia Gubernamental

presentado por Esperanza Citlali García Medina

Para obtener el título de Maestría en Ciencias Computacionales

en la Facultad de Electrónica y Ciencias Computacionales

1 de abril de 2015



### RESUMEN

The Thesis Abstract is written here (and usually kept to just this page). The page is kept centered vertically so can expand into the blank space above the title too...

### Palabras Clave:

The Thesis Abstract is written here (and usually kept to just this page). The page is kept centered vertically so can expand into the blank space above the title too...

### ABSTRACT

The Thesis Abstract is written here (and usually kept to just this page). The page is kept centered vertically so can expand into the blank space above the title too...

### Keywords:

The Thesis Abstract is written here (and usually kept to just this page). The page is kept centered vertically so can expand into the blank space above the title too...

# A grade cimientos

A mi asesor de tesis, el Dr. Rogelio Dávila por sus consejos en el desarrollo de este proyecto.

A mis maestros por todas sus enseñanzas.

A mi marido, Romeo por todo su apoyo y paciencia en mis noches de desvelo y estrés.

A mi familia, por estar ahí siempre.

# Índice general $\overline{}$

Resum	en II
$\mathbf{Agrade}$	cimientos
Índice	de Figuras VI
Índice	de Cuadros VII
Abrevi	aciones
	Datos Abiertos de Gobierno
2. Des	cripción del Problema 5
3. Defi	nición del Problema 8
4. Pre	gunta de Investigación 9
5.1.	Objetivos de la Investigación Objetivo General
6. Res	ıltados Esperados 11
7. Deli	mitación de la Investigación 12
8. Just	ificación 13
9.1. 9.2. 9.3.	Marco Historico y Contextual 14 Marco Referencial 14 Marco Teórico 14 Términos Básicos 14
	ouesta de Solución 15
10.1	Conjunto de Datos
_	lementación de la Solución 16
	Arquitectura
11.2	Detalles Técnicos

Contents	V
12.Resultados	17
A. Resumen de formatos de archivos más comunes	18
B. Ejemplos de implementaciones CKAN en el mundo	19
Bibliografía	29

# Índice de figuras

# Índice de cuadros

## Abreviaciones

 $\mathbf{ODM}$  Open  $\mathbf{D}$ ata  $\mathbf{M}$ ovement

 $\mathbf{OKF}$  Open Knowledge Foundation

 $\mathbf{CKAN} \quad \mathbf{Comprehensive} \ \mathbf{K} \\ \mathbf{nowledge} \ \mathbf{A} \\ \mathbf{r} \\ \mathbf{chive} \ \mathbf{N} \\ \mathbf{e} \\ \mathbf{w} \\ \mathbf{r} \\ \mathbf{k} \\ \mathbf{r} \\ \mathbf{k} \\ \mathbf{r} \\ \mathbf{k} \\ \mathbf{r} \\ \mathbf{r} \\ \mathbf{k} \\ \mathbf{r} \\ \mathbf{r} \\ \mathbf{k} \\ \mathbf{r} \\ \mathbf{$ 

### Introducción

En la última década, un movimiento ha surgido gradualmente en todo el mundo, conocido como el movimiento de los Datos Abiertos (Open Data Movement en Inglés). Su objetivo es la difusión del Conocimiento Abierto en su mas amplio sentido.

La Fundación Conocimiento Abierto (Open Knowledge Foundation en Inglés) define el conocimiento abierto como:

«cualquier contenido, información o dato que puede ser libremente utilizado, reutilizado y redistribuido -sin restricciones legales, tecnológicas o sociales-. [...] El conocimiento abierto es en lo que se convierten los datos abiertos cuando son útiles, usables y utilizados» [1]

Los Datos Abiertos son por ende, la base de construcción en la que se fundamenta el Conocimiento Abierto.

El término de Datos Abiertos es una práctica que tiene como objetivo que determinados tipos de datos estén disponibles para todo el mundo sin restricciones de derechos de autor, patentes u otro mecanismo de control. Dicho concepto no es nuevo, sin embargo, ha ganado mayor relevancia con el aumento en la popularidad de tecnologías como el Internet y la Red Informática Mundial (World Wide Web en Inglés o WWW), así como a la acumulación masiva de datos (Big Data en Inglés).

Introducción 2

La filosofía detrás de éste movimiento se centra en 3 principales aspectos:

1) Disponibilidad y Accesso: Los datos deben de estar disponibles preferentemente mediante una descarga de Internet. Los datos deben de ser presentados en un formato conveniente y que permita modificaciones fácilmente.

- 2) Reutilización y Redistribución: Los datos deben de estar disponibles bajo términos que permitan su reutilización y redistribución, incluida la composición con otros conjuntos de datos. Los datos deben de ser capaces de ser leídos por una computadora.
- 3) Participación Universal: Cualquier persona debe de tener la posibilidad de usar, reutilizar y redistribuir datos abiertos sin discriminación alguna.

Los tipos de Datos Abiertos comprenden campos de estudio muy diversos como lo son Cultural, Científico, Finanzas, Estadística, Climatológica, Ambiental, de Transporte y Gubernamental.

Introducción 3

#### 1.1. Datos Abiertos de Gobierno

Los Datos Abiertos de Gobierno son un proyecto de la Fundación Conocimiento Abierto enfocada exclusivamente a la publicación de datos producidos por instituciones gubernamentales. Varios países incluidos los Estados Unidos Americanos, Reino Unido, Canada, Nueva Zelanda y recientemente México han anunciado sus propias iniciativas hacia la apertura de su información. [2–7]

Ya es posible señalar una gran cantidad de áreas donde los Datos Abiertos de Gobierno están creando valor. Algunos ejemplos de ellos son: [8, 9]

- En términos de transparencia, proyectos como el Finlandés 'árbol de impuestos' o el Británico '¿A donde va mi dinero?' nos muestran como se gasta el dinero de los impuestos por el gobierno. También páginas web como la página Danes folketsting.dk permite monitorear las actividades en el parlamento y el proceso de construcción de leyes para poder saber exactamente qué esta sucediendo y que representantes están involucrados.
- Los Datos Abiertos de Gobierno también pueden ayudar a tomar mejores decisiones en la vida personal, o habilitar a las personas para tener una participación más activa en la sociedad. Una mujer en Dinamarca construyo el sitio web findtoilet.dk para mostrar todos los baños públicos y ayudar a las personas con problemas a salir nuevamente. En Holanda existe un servicio vervuilingsalarm.nl que te advierte con un mensaje de la calidad de el aire en tu comunidad. En Nueva York se puede encontrar fácilmente donde sacar el perro a pasear así como conocer otras personas que frecuentan el mismo parque. Servicios como 'mapumental' en Reino Unido y 'Magnificent' en Alemania te permiten encontrar un lugar para vivir teniendo en consideración la duración de el traslado al trabajo, los precios de las casas y la calidad de el area. Todos estos ejemplos utilizan datos abiertos.
- Económicamente, los datos abiertos también son de gran importancia. Varios estudios han estimado el valor de los datos abiertos es superior a los diez mil millones de Euros anualmente. Nuevos productos y compañías están utilizando esta información por ejemplo, la página web Danesa husetsweb.dk te ayuda a encontrar manera

de mejor la eficiencia energética en el hogar basado en información de los subsidios gubernamentales. Google Translate utiliza la enorme cantidad de documentos abiertos para entrenar sus algoritmos de traducción y por lo tanto mejorando la calidad de su servicio.

Los datos abiertos son de gran valor para el gobierno mismo ya que colabora a incrementar su eficiencia y efectividad. Por ejemplo el Ministerio de Educación Alemán ha publicado toda la información relacionada con educación en linea para su reutlización. Desde entonces, el número de preguntas que ellos reciben a disminuido reduciendo la carga de trabajo y costos.

Aún cuando ya hay numerosos ejemplos de las maneras en que los datos abiertos están creando valor tanto social como económico, todavía hay un área muy grande de oportunidad para descubrir nuevos campos de investigación.

Los sitios web que forman parte de el proyecto Datos Abiertos de Gobierno están desarrollados utilizando una plataforma tecnológica conocida como CKAN (Comprehensive Knowledge Archive Network en Inglés), también mantenida por la Fundación Conocimiento Abierto. CKAN es un sistema para el almacenamiento y distribución de información que provee herramientas para publicar, compartir, buscar y utilizar los datos. CKAN esta enfocado a gobiernos regionales y nacionales, compañías y organizaciones que quieren hacer que sus datos sean abiertos y disponibles al público. [10]

Este documento investiga la estructura e implementación de la plataforma CKAN en diferentes instituciones gubernamentales, particularmente en la plataforma del Gobierno Mexicano, sin embargo será aplicable para cualquier otra institución que este desarrollada utilizando las mismas tecnologías, con la finalidad de proponer una nueva herramienta capaz de extraer la información proporcionada por las instituciones gubernamentales y estructurarla de una manera uniforme utilizando en un formato genérico y permitir así la consulta y análisis de la información de una manera más simple y natural.

### Descripción del Problema

Los catálogo de Datos Abiertos permiten que se creen herramientas de todo tipo para medir y estudiar lo que ocurre a partir de la información recolectada. Nuevas tecnologías permiten ahora construir servicios para responder automáticamente preguntas como: ¿Cuál es el eje carretero más largo en un país? ¿Qué porcentaje del presupuesto se destina para el alumbrado público? ¿En que región existen mejores oportunidades de trabajo? Mucha de la información necesaria para responder estas preguntas es generada por instituciones públicas, sin embargo, frecuentemente la información no esta disponible en un formato que sea fácil de utilizar.

En México, en el año 2014, como parte de la Política de Datos Abiertos, el Gobierno Mexicano ha puesto a disposición de toda la población la mayor cantidad de información posible de todo lo que ocurre en las entidades de Gobierno y con cada programa social que se desarrolla en el país a través de la plataforma llamada datos.gob.mx. De acuerdo con el comunicado oficial del Gobierno Federal, desde dicha página se puede «acceder, descargar, y utilizar libremente los datos abiertos que el Gobierno de la República genera y recolecta, con el fin de innovar, emprender, incrementar la transparencia, eficientar al gobierno y promover la innovación cívica.» [11]

Una investigación realizada en la Universidad de Waterloo en Canada en el año de 2014 analiza diferentes casos de uso de sistemas que fueron implementados utilizando datos abiertos y refleja la complejidad que implica el trabajar con ellos: [12]

- Hay situaciones en las que para poder hacer un analisis se requiere información tanto de instituciones gubernamentales como no gubernamentales. ¿Cómo aseguramos que toda la información necesaria para un proyecto se encuentra disponible?
- Aplicaciones que requieren información de ultimo momento, como una aplicación para predecir el clima, requiere de la información este lo más actualizada posible.

¿Cómo podemos asegurar que la información requerida aún es válida y que sea actualizada en un periodo aceptable de tiempo?

- Algunas veces es necesario consultar información no propia del documento pero de su publicación, por ejemplo, lugar y fecha de publicación ¿Cómo puedo acceder a herramientas que permitan consultar metadata y palabras clave de un documento?
- Liberar datos abiertos puede tener efectos en la privacidad de los individuos afectados cuando alguna información personal pudiera ser inferidos por datos abiertos.
  ¿Cómo puedo asegurar que los datos abiertos que han sido compartidos no implican potenciales problemas de seguridad o privacidad?

Idealmente para un usuario debería ser posible fácilmente realizar tareas tales como: [8]

- Descubir la existencia de determinado conjunto de datos.
- Acceder a los datos para su investigación y análisis.
- Encontrar la información detallada describiendo la información y su proceso de producción.
- Acceder a las fuentes de datos e instrumentos de collección con los cuales la información fue colectada.
- Efectivamente comunicarse con las agencias involucradas en el proceso de producción, almacenamiento y distribución de la información.
- Compartir el conocimiento con otros usuarios.

Sin embargo, la realidad aún se aleja de los ideales de el Movimiento Conocimiento Abierto. No es suficiente con declarar los conjuntos de datos como 'abiertos' para que estos datos tenga un uso práctico para el ciudadano común.

Cuando estos datos son liberados en su formato crudo (raw en Inglés), sólo tienen sentido para los especialistas técnicos que saben como extraerlos, interpretarlos y utilizarlos. De nuevo, esta información sigue estando únicamente a disposición de ciertos grupos privilegiados.

Si se pretende que esta información tenga un alcance masivo y sea significativa para la ciudadanía en general, debemos de enfocarnos en solucionar los principales retos a los que se enfrenta un usuario es su búsqueda de datos abiertos los cuales son:

- La navegación en la plataforma no es intuitiva para un usuario que no este familiarizado con entornos tecnológicos.
- Los formatos en que los datos son presentados son muy diversos, varía desde archivos en formatos zip, csv, xml, json, kmz, etc.
- El motor de búsqueda integrado a la plataforma es poco eficiente por lo que un usuario debe saber de antemano cual es la fuente que esta generado los datos de su interés, de otra manera tiene que recurrir a la búsqueda mediante etiquetas que no siempre pueden estar disponibles.

### Definición del Problema

El presente trabajo acota la investigación a un ejemplo de implementación de plataforma CKAN en particular, siendo el sitio web de Datos Abiertos del Gobierno Mexicano (datos.gob.mx) el seleccionado por ser un ejemplo práctico y de mayor beneficio para la comunidad local.

Cabe destacar que aún cuando la aplicación esta enfocada a esta plataforma, aplica prácticamente a cualquier otra que cuente con la misma estructura, por lo que este prototipo puede ser reutilizable y ajustarse a otras necesidades de implementación.

Con ésta aplicación se pretende contribuir a el desarrollo de herramientas que pongan a el alcance de todo el mundo la información pública que las instituciones gubernamentales nos proporcionan con la finalidad de despertar en ellos la creatividad y que en un futuro cercano surjan ideas inovadoras e interesantes maneras de interpretar los datos abiertos.

## Pregunta de Investigación

¿Cómo desarrollar una aplicación que permita generar valor a partir de la consulta, uso y análisis de los datos abiertos liberados por las organizaciones gubernamentales a una audiencia más amplia y de manera fácilmente accessible?

### Objetivos de la Investigación

#### 5.1. Objetivo General

Desarrollar una aplicación que permita extraer los datos abiertos disponibles en una plataformas CKAN y que una vez obtenidos, los diferentes tipos de archivos que existen en diversos formatos sean estructurados uniformemente, de tal manera que se puedan consultar y analizar de una manera más simple y natural.

#### 5.2. Objetivos Particulares

- 1. Desarrollar un programa que inspeccione las páginas de una manera metódica y automatizada (Web Crawler en Inglés) para navegar a través del sitio datos.gob.mx y descargar la información requerida utilizando el API de CKAN y un script en lenguaje Python.
- 2. Desarrollar un algoritmo para el procesamiento e indexado de la información que produzca como resultado archivos en formato JSON.
- 3. Proveer las capacidades de búsqueda de texto y definir un lenguaje de consulta utilizando las capacidades que la herramienta Apache Lucene proporciona.

# Resultados Esperados

# Delimitación de la Investigación

## Justificación

### Bases Teóricas

- 9.1. Marco Historico y Contextual
- 9.2. Marco Referencial
- 9.3. Marco Teórico
- 9.4. Términos Básicos

# Propuesta de Solución

10.1. Conjunto de Datos

## Implementación de la Solución

- 11.1. Arquitectura
- 11.2. Detalles Técnicos

## Resultados

#### Resumen de formatos de archivos más comunes

#### **JSON**

Acrónimo de JavaScript Object Notation, es un formato ligero para el intercambio de datos. JSON es un subconjunto de la notación literal de objetos de JavaScript que no requiere el uso de XML.

#### XML

Siglas en inglés de eXtensible Markup Language ('lenguaje de marcas extensible'), es un lenguaje de marcas desarrollado por el World Wide Web Consortium (W3C) utilizado para almacenar datos en forma legible.

#### XLS

La extensión de archivo por defecto para aplicaciones de hojas de cálculo.

#### CSV

Tipo de documento en formato abierto sencillo para representar datos en forma de tabla, en las que las columnas se separan por comas y las filas por saltos de línea.

#### TXT

La extensión para archivo compuesto únicamente por texto sin formato, sólo caracteres, lo que lo hace también legible por humanos.

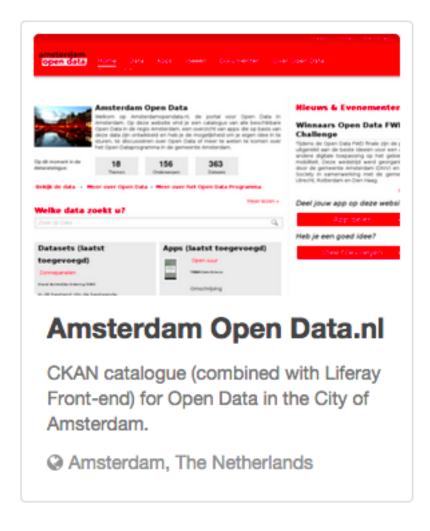
#### ZIP

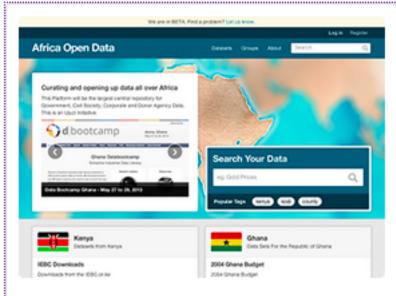
Formato de compresión sin pérdida, muy utilizado para la compresión de datos como documentos, imágenes o programas.

#### KMZ

Es un lenguaje de marcado basado en XML para representar datos geográficos en tres dimensiones en formato comprimido.

## Ejemplos de implementaciones CKAN en el mundo

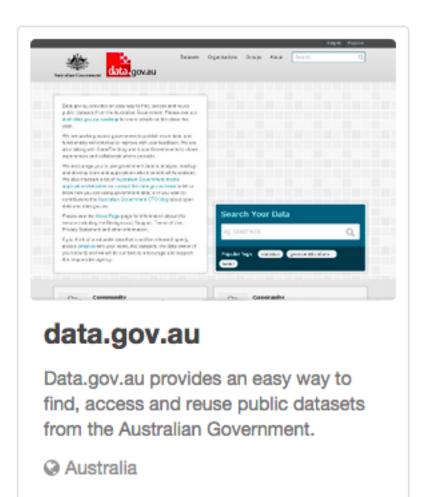


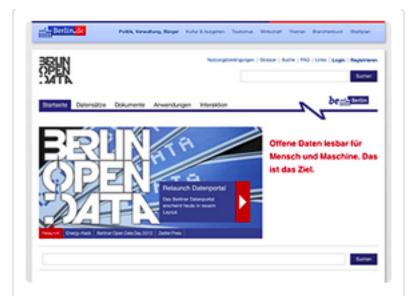


## **Africa Open Data**

The Open Africa Platform initiative aims to be largest repository of Data on the African continent - a Library of Congress of Data for African for use by citizens, media, activists, governments and civil society. It is part of the Ujuzi Initiative which is created and funded by the Africa Media Initiative (AMI), the World Bank Institute (WBI) and Google.

Africa

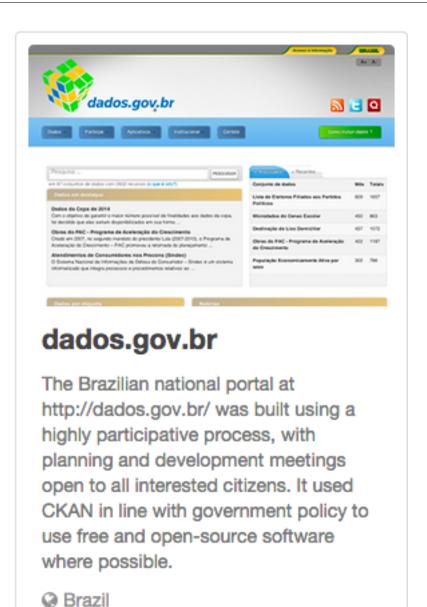




## **Berlin Open Data**

Berlin Open Data provides data held by the State of Berlin. It was built in collaboration with the German chapter of the Open Knowledge Foundation.

Berlin, Germany





## **Buenos Aires Data**

Buenos Aires Data was launched by the Buenos Aires city government in March 2012, running CKAN 1.5. It was upgraded to version 1.7 in July 2012.

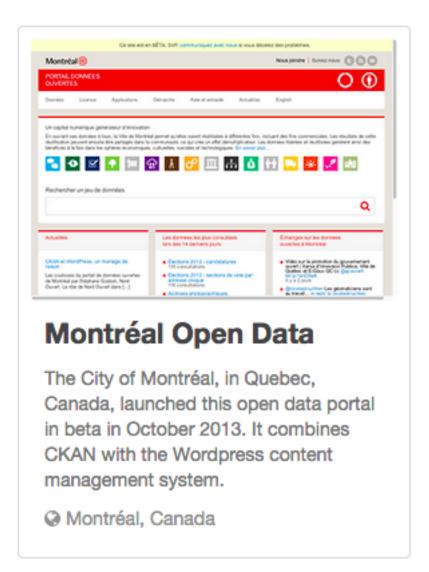
Buenos Aires, Argentina



# datos.gob.mx

Open data website by the Federal Public Administration of the United Mexican States.

Mexico





## Data.gov.uk

The UK's http://data.gov.uk/ was one of the first government data portals on its launch in 2009, using Drupal to build the site and CKAN as a back-end. It was relaunched in June 2012 with data search pages now presented directly by CKAN.

United Kingdom



## Data.gov

The US government announced in January 2013 that they were moving to CKAN for their open data catalogue, combining datasets previously published in different places. The relaunch went live in May 2013.

USA

### Bibliografía

- [1] Open Knowledge. What is open?, Febrero 2015. URL https://okfn.org/opendata/.
- [2] Open Government Data. Open government data, Diciembre 2014. URL http://opengovernmentdata.org/.
- [3] Data.Gov. U.s. government open data, Enero 2015. URL http://www.data.gov/.
- [4] Data.Gov. U.k. government open data, Enero 2015. URL http://data.gov.uk/.
- [5] Data.Gov. Canada government open data, Enero 2015. URL http://open.canada.ca/en.
- [6] Data.Gov. New zealand government open data, Enero 2015. URL https://data.govt.nz/.
- [7] Data.Gov. Mexico government open data, Enero 2015. URL http://datos.gob.mx/.
- [8] Open Knowledge. Open data handbook, Diciembre 2014. URL http://opendatahandbook.org/pdf/OpenDataHandbook.pdf.
- [9] UK Government. Open data white paper unleashing the potential, Febrero 2015. URL https://www.gov.uk/government/uploads/system/uploads/attachmentdata/file/78946/CM8353acc.pdf.
- [10] CKAN. The open source data software portal, Diciembre 2014. URL http://ckan. org/.
- [11] Presidencia de la República. ¿ya conoces datos.gob.mx?, Junio 2014. URL http://www.gob.mx/presidencia/datos-abiertos/ya-conoces-datos-gob-mx/.

Bibliography 30

[12] Cowan D.; Alencar P.; McGarry F. Perspectives on open data: Issues and opportunities. Software Science Technology and Engineering (SWSTE) 2014 IEEE International Conference on, pages 24–33, June 2014. URL http://link.aip.org/link/?RSI/62/1/1.